

Trabalho Final de Inteligência Artificial

Classificação de Espécies de Flores Iris com KNN e Random Forest

Integrantes

- Luigi Biagio Antonioli - RA: 23329385-2
 - Francisco Guilherme Soares dos Santos - RA: 23389027-2
-

1. Resumo do projeto

Este trabalho foi desenvolvido para a disciplina de Inteligência Artificial, com o objetivo de aplicar, de forma prática, conceitos de aprendizado de máquina.

O projeto tem como tema a classificação de espécies de flores Iris utilizando dois modelos de Inteligência Artificial supervisionados: KNN e Random Forest.

A partir das medidas da sépala e da pétala de uma flor, os modelos devem prever corretamente a espécie da flor, podendo ser Iris-setosa, Iris-versicolor ou Iris-virginica.

Ao final do projeto, os dois modelos são avaliados por meio de métricas e gráficos, permitindo comparar seus desempenhos e identificar qual apresentou melhor resultado.

2. Contextualização do tema

A Inteligência Artificial pode ser utilizada para identificar padrões em conjuntos de dados e realizar previsões ou classificações. Neste trabalho, esse conceito foi aplicado em um problema de classificação de flores.

O dataset Iris é bastante conhecido na área de aprendizado de máquina por ser simples, organizado e de fácil entendimento. Ele permite demonstrar de forma prática como modelos supervisionados conseguem aprender padrões a partir de dados já classificados.

3. Problema investigado

O problema investigado neste projeto é de classificação supervisionada.

A pergunta principal do trabalho é:

Com base nas medidas da sépala e da pétala, é possível classificar corretamente a espécie de uma flor Iris?

Os modelos recebem como entrada as medidas da flor e devem prever a espécie correta.

As possíveis espécies são:

- Iris-setosa.
 - Iris-versicolor.
 - Iris-virginica.
-

4. Hipótese da equipe

A hipótese inicial da equipe é que o modelo Random Forest poderá apresentar melhor desempenho em comparação ao KNN.

Essa hipótese se baseia no fato de que o Random Forest utiliza várias árvores de decisão em conjunto, aplicando o conceito de ensemble. Isso pode tornar o modelo mais robusto e reduzir erros de classificação.

Por outro lado, o KNN também pode apresentar bons resultados, pois o dataset Iris possui atributos numéricos simples e bem organizados.

5. Dataset utilizado

O dataset escolhido foi o Iris Flower Dataset.

Neste projeto, o dataset foi carregado diretamente pela biblioteca scikit-learn, utilizando a função `load_iris()`.

O dataset possui:

- 150 registros.
- 4 atributos numéricos.
- 3 classes de flores Iris.

Os atributos utilizados como entrada para os modelos são:

- SepalLengthCm: comprimento da sépala.
- SepalWidthCm: largura da sépala.
- PetalLengthCm: comprimento da pétala.
- PetalWidthCm: largura da pétala.

A variável alvo é a espécie da flor, representada pela coluna Species.

As classes possíveis são:

- Iris-setosa.
 - Iris-versicolor.
 - Iris-virginica.
-

6. Origem dos dados

O dataset Iris está disponível na biblioteca scikit-learn e também é conhecido pelo UCI Machine Learning Repository.

Fontes utilizadas:

- Scikit-learn: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html
 - UCI Machine Learning Repository: <https://archive.ics.uci.edu/dataset/53/iris>
-

7. Preparação dos dados

Antes do treinamento dos modelos, os dados passaram por algumas etapas de preparação.

As principais etapas foram:

1. Carregamento do dataset Iris com a função `load_iris()`.
2. Conversão dos dados para uma tabela utilizando pandas.
3. Renomeação das colunas para facilitar a compreensão.
4. Conversão das classes numéricas para os nomes das espécies.
5. Verificação de valores ausentes.
6. Separação entre atributos de entrada e variável alvo.
7. Divisão dos dados em treino e teste.
8. Normalização dos dados para o modelo KNN.

A divisão dos dados foi feita da seguinte forma:

- 80% dos dados para treino.
- 20% dos dados para teste.

Os dados de treino foram utilizados para os modelos aprenderem os padrões presentes no dataset. Já os dados de teste foram utilizados para avaliar se os modelos conseguem classificar corretamente dados que não foram vistos durante o treinamento.

8. Métodos de Inteligência Artificial utilizados

Neste projeto, foram utilizados dois modelos de aprendizado de máquina supervisionado:

- KNN — K-Nearest Neighbors.
- Random Forest.

Os dois modelos foram treinados com o mesmo dataset e avaliados com as mesmas métricas, permitindo uma comparação justa entre os resultados.

9. KNN — K-Nearest Neighbors

O KNN é um algoritmo de aprendizado de máquina supervisionado utilizado para problemas de classificação e regressão.

Ele funciona comparando um novo dado com os exemplos já existentes no conjunto de treinamento. Para isso, calcula a distância entre os dados e identifica os K vizinhos mais próximos.

Em problemas de classificação, o KNN utiliza votação entre os vizinhos mais próximos para definir a classe final.

Neste projeto, o KNN foi utilizado para classificar a espécie da flor Iris com base nas medidas da sépala e da pétala.

10. Random Forest

O Random Forest é um algoritmo de aprendizado de máquina supervisionado que utiliza várias árvores de decisão para realizar classificações ou previsões.

Cada árvore realiza uma previsão separadamente. Depois, o resultado final é definido pela votação da maioria das árvores.

Neste projeto, o Random Forest foi utilizado para comparar seu desempenho com o KNN na classificação das espécies de flores Iris.

11. Conceito de Ensemble

O Random Forest é considerado um método ensemble.

Ensemble é uma técnica que combina vários modelos para formar um modelo mais forte e confiável.

No caso do Random Forest, várias árvores de decisão são treinadas e suas respostas são combinadas. Dessa forma, mesmo que algumas árvores errem, a maioria pode acertar, tornando o resultado final mais robusto.

12. Avaliação dos modelos

Os modelos foram avaliados utilizando métricas comuns em problemas de classificação.

As métricas utilizadas foram:

- Acurácia.
- Precisão.
- Revocação.
- F1-score.
- Matriz de confusão.

A acurácia mostra a porcentagem geral de acertos do modelo.

A precisão mostra, entre as previsões feitas para uma classe, quantas estavam corretas.

A revocação mostra quantos exemplos reais de uma classe foram identificados corretamente pelo modelo.

O F1-score é uma média entre precisão e revocação, sendo útil para avaliar o equilíbrio do modelo.

A matriz de confusão mostra os acertos e erros do modelo, permitindo visualizar quais classes foram classificadas corretamente e quais foram confundidas.

13. Gráficos de avaliação

Durante a execução do notebook, foram gerados gráficos para comparar o desempenho dos modelos.

13.1 Comparação das métricas entre KNN e Random Forest

INSERIR AQUI O GRÁFICO: graficos/comparacao_modelos.png

13.2 Matriz de confusão do KNN

INSERIR AQUI O GRÁFICO: graficos/matriz_knn.png

13.3 Matriz de confusão do Random Forest

INSERIR AQUI O GRÁFICO: graficos/matriz_random_forest.png

14. Comparação dos resultados

Após o treinamento, os modelos KNN e Random Forest foram comparados com base nas métricas calculadas.

A comparação teve como objetivo verificar:

- Qual modelo apresentou maior acurácia.
- Qual modelo apresentou melhor precisão.
- Qual modelo apresentou melhor revocação.
- Qual modelo apresentou melhor F1-score.
- Se o Random Forest teve melhor desempenho por utilizar ensemble.
- Se o KNN conseguiu obter desempenho semelhante.

Com essa comparação, foi possível analisar qual modelo foi mais eficiente para o dataset escolhido.

15. Conclusão

O projeto permitiu aplicar, de forma prática, as principais etapas de desenvolvimento de uma solução baseada em Inteligência Artificial.

Foram realizadas as etapas de escolha do dataset, preparação dos dados, treinamento dos modelos, avaliação com métricas, geração de gráficos e comparação dos resultados.

O KNN foi utilizado como um modelo mais simples, baseado na proximidade entre os dados. Já o Random Forest foi utilizado como um modelo mais robusto, baseado em várias árvores de decisão e no conceito de ensemble.

Com a comparação dos resultados, é possível concluir qual modelo apresentou melhor desempenho na classificação das espécies de flores Iris.

16. Estrutura do repositório

O repositório do projeto contém os principais arquivos necessários para a entrega:

- README.md.
- requirements.txt.
- Notebook do projeto.
- Gráficos gerados.
- Modelos treinados.

Estrutura utilizada:

TRABALHO_FINAL_IA/

- graficos/
 - comparacao_modelos.png
 - matriz_knn.png
 - matriz_random_forest.png
 - modelos/
 - modelo_knn.pkl
 - modelo_random_forest.pkl
 - notebooks/
 - trabalhoFinal_IA.ipynb
 - README.md
 - requirements.txt
-

17. Como executar o projeto

O projeto pode ser executado no Google Colab ou em ambiente local com Python.

Para executar no Google Colab:

1. Abrir o notebook localizado na pasta notebooks.
2. Executar as células em ordem.
3. O dataset será carregado automaticamente pelo scikit-learn.
4. Os modelos KNN e Random Forest serão treinados.
5. As métricas e gráficos serão gerados ao final da execução.

Para executar localmente:

1. Clonar o repositório.
 2. Instalar as dependências do arquivo requirements.txt.
 3. Abrir o notebook em um ambiente Jupyter Notebook ou Jupyter Lab.
 4. Executar as células em ordem.
-

18. Dependências

As principais bibliotecas utilizadas no projeto foram:

- pandas.
 - numpy.
 - matplotlib.
 - scikit-learn.
 - joblib.
-

19. Resumo final

Este trabalho comparou os modelos KNN e Random Forest na classificação de espécies de flores Iris.

O KNN realizou a classificação com base nos vizinhos mais próximos, enquanto o Random Forest utilizou várias árvores de decisão em conjunto, aplicando o conceito de ensemble.

A comparação entre os modelos foi feita por meio de métricas e gráficos, permitindo analisar qual algoritmo apresentou melhor desempenho para o problema proposto.